

数据工程师 / 高级后端工程师

袁耿耿(Yuan Genggeng)

✉ kidyuan@foxmail.com | 📞 070-4017-5377

📍 日本东京

签证:技术·人文知识·国际业务(3年)

作品展示: [Olist Lakehouse Pipeline](#) | [perapera.me](#) | [PeraTube](#)

个人简介

数据工程师兼高级后端工程师,在大规模分布式系统、高并发数据库迁移及云原生架构领域拥有 **6 年以上** 专业经验,并具备 20 年软件工程积累。目前正全面转向现代 **Lakehouse 数据工程**,对 **Databricks**、**PySpark**、**Delta Lake**(**Medallion 架构**、**Lakeflow Pipelines**、**Unity Catalog**、**CDC/SCD Type 2**) 有深入的实战掌握。在多层数据管道编排、维度建模,以及打通企业数据湖与实时业务应用的端到端闭环方面有成熟经验。精通 Spring 生态、NoSQL(Cassandra、Couchbase)及 AI 辅助研发 workflow。

技术技能

核心能力

- **数据工程与 Lakehouse**:**Databricks**、**PySpark**、**Delta Lake**(ACID、MERGE INTO、Time Travel、CDF、Liquid Clustering)、**Auto Loader**、**Databricks Asset Bundles(DABs)**、**Lakeflow Pipelines(DLT)**、**Unity Catalog**、Medallion 架构(Bronze/Silver/Gold)、**SCD Type 2**、**CDC**、维度建模(星型模型)、窗口去重、SQL
- **分布式后端与数据系统**:Java、Kotlin、Python(FastAPI)、**Spring Boot(2.x/3.x)**、**Kafka(CDC)**、**Cassandra**、Couchbase、Snowflake、Oracle、Redis、RabbitMQ、微服务、DDD
- **搜索与实时同步**:**Meilisearch**、Convex(响应式 WebSocket 推送)、Elasticsearch/向量检索、RESTful API
- **云与 DevOps**:**Azure(Static Web Apps、AKS)**、**Railway**、AWS、Docker、Minikube、Podman、CI/CD(GitHub Actions、GitLab CI/CD)
- **AI 辅助研发**:熟练使用 **Claude Code**、**Codex**、**Antigravity** 进行快速开发、代码生成及数据管道重构

编程语言与框架

- **编程语言**:Python、Java、Kotlin、SQL、TypeScript、C#、Go、Rust、C++
- **Web 与前端**:Next.js、React.js、Vue.js、Convex、Tailwind CSS
- **语言能力**:日语(商务水平)、英语(商务水平)、中文(母语)

代表项目

[Olist Lakehouse Pipeline](#) — 基于 Databricks 的生产级增量 Lakehouse

数据工程作品 | 架构师兼数据工程师

代码仓库: <https://github.com/kidwon/olist-lakehouse-pipeline>

- **生产级 Medallion 架构**:基于 Databricks 构建增量 Medallion Lakehouse,处理 10 万+ 条巴西电商真实订单(Olist 数据集),按日回放数据流,依次经过 Landing、Bronze、Silver、Gold 直至业务数据集市(Business Marts)。
- **幂等摄取与 CDC 处理**:
 - 利用 **Auto Loader** 的检查点与 `_rescued_data` 支持 Schema 演进,出现意外字段(`discount_amount`)时依然零数据丢失。
 - 基于序列号(`change_seq`)实现**只进不退的 CDC MERGE**,确保乱序的状态更新不会导致订单状态回退。
 - 通过窗口去重(`row_number`)与仅 INSERT 的 MERGE,消除批内及跨批次重复投递产生的重复数据。
- **手写 SCD Type 2 与时点关联(Point-in-Time Join)**:设计基于变更哈希的检测机制,在单次原子 MERGE 中完成历史记录关闭与新版本插入,用于追踪卖家地址变化;事实表(`fact_order_item`)按交易日期关联维度,防止指标漂移。
- **数据质量闸门与自动隔离**:建立按规则划分的隔离表(`ops.quarantine`)及自动执行闸门(`ops.dq_gate`),异常率超过 5% 时阻断下游 Gold 层发布,并完整记录运行指标(`ops.dq_metrics`)。
- **星型模型与业务数据集市**:将 Gold 层构建为 Kimball 星型模型(`fact_order_item`、`dim_date`、基于 `customer_unique_id` 归并的 `dim_customer`、`dim_product`、`dim_seller`),并构建卖家履约表现数据集市(GMV、准时送达率、评分趋势)。
- **CI/CD、测试与决策记录**:使用 **Databricks Asset Bundles(DABs)** 打包包含 7 个任务的 Serverless 工作流;实现 28 个自动化单元测试与端到端测试(`pytest`),验证异常注入与检测 100% 一致;撰写 8 份完整的架构决策记录(ADR)。

perapera.me — 高性能日语学习生态平台

个人项目 | 首席全栈架构师

- **架构**:基于 **Next.js/Convex** 与 **FastAPI** 构建混合多服务平台。
- **搜索引擎**:集成 **Meilisearch**,实现对数百万条记录的高性能检索。
- **高可用 AI**:实现多级降级架构(缓存/Key 池/DeepSeek),应对严格的 LLM 速率限制。
- **云与支付**:通过 GitHub Actions 编排 CI/CD 管道,部署至 **Azure** 与 **Railway**,并集成 **Stripe** 订阅支付。

PeraTube — 日语视频例句检索 API(开发者 SaaS)

个人项目 | 独立全栈架构师

- **产品**:将海量 YouTube 字幕语料索引为可检索片段,开发者可通过 API 查询日语在真实视频中的实际用法,以毫秒级延迟返回视频 ID、时间戳、字幕文本及上下文。
- **架构**:**Next.js** 控制台/Playground + **Python FastAPI** 编排层 + 作为唯一数据源(用户、配额、API Key)的 **Convex + Meilisearch** 全文检索。
- **商业化**:**Stripe** 订阅与点数包、API Key 认证(`sha256` 哈希、LRU 缓存校验)、在 Convex 中原子扣减配额、管理后台及内容审核。
- **数据管道与质量**:YouTube → VTT 字幕 → 片段解析 → 分块 `.jsonl` → 批量导入;API 与管道共覆盖 15+ 个 `pytest` 测试文件;部署于 **Railway**,使用 Cloudflare 自定义域名。

Jessie Signal — 实时市场情绪看板

个人项目 | 全栈架构师

- 基于 **React / Convex** 构建 Serverless Web 应用,聚合实时市场数据(**VIX**、**CNN 恐惧与贪婪指数**、**主要 ETF**),并将市场划分为可执行的情绪场景。
- 实现**用户认证(Clerk)**,用户登录后可**订阅市场场景变化的邮件提醒**,通过 **Resend** 发送。
- 增加**服务端缓存层**以实现页面秒开,并提供带权限控制的**管理后台**;部署于 **Railway**。

工作经历

合同制后端工程师 | NTT DATA

2025年4月 - 2026年8月 | 日本东京

保险系统现代化项目(**Struts** 迁移至 **Spring**)

工作职责:

- 分两个主要阶段参与核心保险应用的全栈现代化改造,推动从遗留框架迁移至现代 Web 应用技术栈:
 - **迁移前遗留技术栈**:TERASOLUNA 2.2.0(Struts 1.x)+ Oracle 11g + intra-mart 7.2 + JDK 1.7
 - **迁移后现代技术栈**:TERASOLUNA 5.x(Spring MVC)+ Oracle 18c XE + intra-mart 8.0.36 + JDK 17 (架构迁移、框架升级、*Spring* 生态)
- **阶段一(UI/UX 优化)**:在保留原有 Struts 后端过滤器及 Java 逻辑的前提下,重构遗留 **JSP** 模板并调整 intra-mart 自定义标签,提升前端易用性。(*JSP 重构、intra-mart 生态、Struts 1.x*)
- **阶段二(架构升级)**:运用**依赖注入**及现代 Spring 范式,将后端业务逻辑层重构为清晰、解耦、可测试的 Spring 托管 Bean。(*Spring Core、Java 17、后端工程*)

技术与环境:Java 17、Spring MVC(TERASOLUNA 5.x)、Struts 1.x(TERASOLUNA 2.2.0)、intra-mart 7.2 / 8.0.36、JSP、Oracle 11g / 18c XE、Eclipse

合同制后端工程师 | 乐天集团(Rakuten Group, Inc.)

2021年9月 - 2025年3月 | 日本东京

会员系统与数据库迁移(**Kotlin/Spring Boot** 微服务)

工作职责:

- 主导关键 PoC(概念验证),测试 Couchbase 在高并发、高流量条件下的承载能力,生成 3 亿条模拟会员数据用于基准测试。(*PoC、数据库基准测试、高并发测试*)
- 深度压测发现 Couchbase 在并发负载下节点重平衡期间出现性能下降和高错误率后,参与执行从 Couchbase 到 **Cassandra** 的数据库迁移。(*数据库迁移、NoSQL、容错*)
- 基于异步框架 **Vert.x** 开发高性能基准测试 API 服务器,用于生成和处理 3 亿条压测模拟数据。(*Vert.x、数据生成、后端开发*)
- 在 CaaS 环境中使用 **Gatling** 执行分布式压力测试,并将自动化测试场景集成至 **GitLab CI/CD** 管道。(*Gatling、负载测试、GitLab CI/CD*)
- 开发并打包自定义 **Argon2** 哈希库,统一多个微服务间的安全数据操作。(*Kotlin、Argon2、安全*)
- 参与会员服务的代码重构,将重复的数据访问逻辑抽取至共享核心模块,降低技术债务。(*代码重构、整洁代码*)
- 使用 **Postman** 和 **Newman** 为迁移后的 RESTful 接口设计并自动化集成测试与回归测试套件,在本地 **MiniKube** 及预发布环境中执行。(*Postman、Newman、API 测试、MiniKube*)

- 更新 **OpenAPI(Swagger)** 文档,确保数据库迁移期间跨团队协作有清晰的 API 规范。(OpenAPI、Swagger、API 文档)

技术与环境:Kotlin、Java、Spring Boot、Vert.x、Cassandra、Couchbase、MariaDB、Gatling、Postman、Newman、GitLab CI/CD、Podman、MiniKube、IntelliJ IDEA

电商平台(Rakuten Fashion - 代理商订单管理系统)

工作职责:

- 于项目后期加入,参与 Rakuten Fashion 代理商订单管理系统的开发与优化。(电商运营、订单管道)
- 基于 **@Scheduled** 与 **RabbitMQ** 开发轻量级 **Spring Boot 定时批处理任务**,实现错误处理自动化,定期将滞留或未处理的订单重新投递至消息队列进行异步重处理。(Spring Boot、@Scheduled、RabbitMQ、异步处理)
- 借助 **JFrog Artifactory** 审查并精简多个微服务仓库中的遗留 **Gradle** 构建配置及内部 API 版本管理,解决版本依赖冲突。(Gradle、JFrog Artifactory、依赖管理)
- 在所有后端服务中集成原生 **Spring Boot OpenAPI(Swagger)** 扩展,统一 API 规范,为跨团队协作建立清晰的接口契约。(Spring Boot、OpenAPI、Swagger、API 标准化)
- 通过更新 Confluence 上的企业技术规格文档、维护关系型数据库 Schema 及 **DDL** 迁移文档,开展初期业务领域分析。(技术文档、Confluence、DDL、数据库 Schema 管理)

技术与环境:Java、Spring Boot、RabbitMQ、Gradle、JFrog Artifactory、OpenAPI、Swagger、MariaDB、Confluence

早期经历

- **正式员工 高级软件工程师 | Techoes 株式会社,东京(2020年1月 - 2021年8月)**
 - 参与多人在线游戏后端开发,使用 **Go**、**gRPC**、**Protobuf** 构建高并发、低延迟微服务,主导在线聊天系统与 AI 寻路模块。
 - 参与直播平台开发,从交互式前端开发(**Vue.js**、**Pixi.js**)逐步转向后端 API 开发与性能优化(**PHP/Laravel**)。
- **合同制软件工程师 | NEC,东京(2018年8月 - 2019年10月)**
 - 为日本警察厅开发 VMS(视频管理系统)集成,基于企业级平台 **Milestone XProtect VMS** 开发 C# 模块扩展(Windows/VS2017)。
 - 为 **Mobile Suica** 系统开发后端 API、Web 界面及定时批处理任务,全面负责从核心实现到单元测试规格设计及测试执行。
- **客户端主程 | 上海 Thinky Game,中国(2016年7月 - 2018年2月)**
 - 负责 3D 手游坦克对战游戏《坦克雄心》(**Unity 5.x**、**C#**)的客户端架构设计与开发管理。
 - 实现核心战斗系统,包括动态炮弹弹道物理、装甲穿深伤害、命中判定、特效管理器、动态天气系统及自定义编辑器工具。
 - 针对内存、CPU、GPU 管线进行底层性能分析与优化,使低端设备也能保持高帧率。
- **客户端工程师 | 上海 Haymaker Game,中国(2015年12月 - 2016年6月)**

- 为动作 RPG 手游《小李飞刀》(**Unity 4.x、C#、SVN**)开发核心战斗逻辑与角色技能释放系统,专注于高频操作输入与状态管理。
 - **UI 与客户端工程师 | 2K Games China,中国**(2015年3月 – 2015年11月)
 - 为 3A 级 PC 游戏《Borderlands Online》(**Unity 4.x、ActionScript 3、C#**)开发事件驱动 UI 框架与 HUD 系统,使用 **Perforce** 将 Scaleform/Flash 界面与 C++ 底层游戏引擎集成。
 - **客户端工程师 | 上海 Hanniu Game,中国**(2014年3月 – 2015年2月)
 - 为 MOBA 手游《暴走DOTA》(**Unity 4.x、C#**)构建实时战斗模块与技能 UI 系统,优化客户端网络包序列化与渲染性能。
 - **UI 与客户端工程师 | Limbo Studio,中国**(2011年4月 – 2014年3月)
 - 使用 **C++、ActionScript 2 及 Flash** 开发 PC 棋牌游戏平台《新安游》的 UI 与客户端逻辑。
 - 使用 **Unreal Engine 2.5(C++、ActionScript 3)** 为 PC 第三人称射击游戏《枪神》开发客户端 UI 模块与 HUD 机制,实现 UI 组件与 UE 原生 C++ 核心模块的对接。
 - **UI 程序员 | 第九城市(The9 Limited),中国**(2007年12月 – 2011年3月)
 - 基于 **Gamebryo C++ 引擎**、ActionScript 2 及 Flash,为 PC 休闲网游《小小部落》开发交互式客户端 UI 模块与业务逻辑。
 - **游戏 QA 与运营专员 | Wemade 上海,中国**(2003年10月 – 2007年12月)
 - 负责 PC 端 MMORPG《传奇3》(Legend of Mir 3)的 GM 运营与技术 QA,开展服务器负载验证、线上测试服环境排障及运营反馈闭环。
 - **计算机教师 | 天台城西中学,中国**(2002年9月 – 2003年9月)
 - 教授计算机科学基础与常用软件操作,培养了良好的技术沟通与表达能力。
-

教育背景

- **浙江工业大学**
 - 计算机应用与维护